

电商实时数据分析系统

课程名称： Hadoop 部署实训实践

题 目： 电商实时数据分析系统

成 员： 何慧娴

学 号： 202306174204

专业班级： 2023 级大数据管理与应用 2 班

目 录

第 1 章 引言	3
1.1 项目设计需求	3
1.2 项目功能要求	3
1.2.1 数据采集与传输	3
1.2.2 多维度实时计算	3
第 2 章 项目设计方案	4
2.1 开发平台	4
2.1.1 大数据组件版本	4
2.2 开发语言	4
2.2.1 Python 核心开发	4
2.2.2 配置脚本语言	5
2.3 设计实现方案	5
2.3.1 系统架构设计	5
2.3.2 技术选型理由	6
2.4 软件流程图	7
第 3 章 项目设计实现	8
3.1 主程序设计	8
3.1.1 数据生产模块	8
3.1.2 实时计算引擎	9
3.2 模块设计	11
3.2.1 模块一：Kafka 消息队列	11
3.2.2 模块二：Spark 流式计算	11
3.2.3 模块三：Redis 数据存储	11
3.2.4 模块四：Streamlit 可视化	12
3.2.5 模块五：监控与日志	13
3.3 程序运行效果	13
3.3.1 效果一：商品排行实时展示	13
3.3.2 效果二：分钟级 UV 趋势	14
3.3.3 效果三：转化漏斗分析	14
3.3.4 效果四：品类热度分布	15
3.3.5 效果五：系统整体稳定性	16
第 4 章 问题与复盘	16
4.1 典型问题深度复盘	16
第 5 章 总结与体会	18
5.1 核心收获	18
5.2 后续优化方向	19
5.3 实验体会	19
附录	21

第 1 章 引言

1.1 项目设计需求

随着电子商务业务的快速发展，海量用户行为数据的实时处理与分析已成为企业核心竞争力的关键要素。传统的离线批处理模式（如每日 T+1 报表）已无法满足现代电商业务对实时性的迫切需求。在促销活动、秒杀抢购等高并发场景下，运营人员需要秒级监控商品热度变化，及时调整推荐策略和库存分配；产品团队需要实时追踪用户转化漏斗，快速定位流失环节并优化用户体验。

本系统旨在构建一套完整的电商实时数据分析平台，实现从数据采集、实时计算、结果存储到可视化展现的全链路处理。系统需要解决以下核心问题：每秒数万条用户行为数据的高并发写入、多维度指标的并行实时计算、计算结果的低延迟持久化与查询、以及直观友好的数据可视化展示。通过本项目的实施，能够深入理解流式计算框架的工作原理，掌握分布式消息队列和内存数据库的协同使用方法，培养大数据系统的设计与调优能力。

1.2 项目功能要求

本系统基于 Spark Structured Streaming + Kafka + Redis + Streamlit 技术栈，需要实现以下核心功能模块：

1.2.1 数据采集与传输

系统需要模拟电商用户行为数据的实时产生，并通过分布式消息队列进行高吞吐传输。数据源为包含用户 ID、商品 ID、品类 ID、行为类型（浏览/购买/加购/收藏）和时间戳的 CSV 文件。需要实现可调节速率的数据发送，支持 10-50 倍速的压力测试场景。

1.2.2 多维度实时计算

系统需要并行计算四类核心指标：商品 PV 排行（按商品 ID 分组计数）、品类热

度排行（按品类 ID 分组计数）、分钟级 UV 统计（基于滑动窗口的去重用户计数）、以及商品转化率分析（PV 到购买的转化比例）。计算过程需要处理数据乱序问题，允许一定时间范围内的延迟数据参与计算。

1.2.3 结果存储与查询

计算结果需要实时写入内存数据库，支持高并发读取。针对不同指标特性，需要选用合适的数据结构：有序集合（ZSet）用于排行榜、集合（Set）用于 UV 去重、哈希（Hash）用于转化率明细、字符串（String）用于累计计数器。

1.2.4 可视化大屏展示

系统需要提供 Web 端实时数据大屏，包含商品排行 Top10 表格与柱状图、分钟级 UV 趋势图、转化漏斗图、品类热度环形图等可视化组件。支持 2 秒级自动刷新，并允许用户调节刷新频率。

第 2 章 项目设计方案

2.1 开发平台

本系统开发及运行环境为 Windows 11 操作系统，采用本地单机部署模式进行开发与测试。所有组件均运行在同一台物理机上，便于调试和问题定位。生产环境建议迁移至 Linux 服务器集群，以获得更好的稳定性和性能表现。

2.1.1 大数据组件版本

Apache Kafka 4.1.0（KRaft 模式）：分布式流处理平台，承担高吞吐消息队列职责。4.x 版本移除了 Zookeeper 依赖，采用 KRaft 自管理元数据模式，简化了部署架构。

Apache Spark 3.4.1：统一分析引擎，Structured Streaming 模块提供流式计算能力。通过微批次处理模型，在流处理的低延迟与批处理的高吞吐之间取得平衡。

Redis 7.4.0：开源内存数据结构存储系统，作为计算结果的实时存储层。利用内存操作的高性能特性，确保数据写入和查询的毫秒级响应。

2.2 开发语言

2.2.1 Python 核心开发

系统主要采用 Python 3.12 进行开发，利用其丰富的数据科学生态和简洁的语法特

性。关键依赖库包括：pyspark（Spark Python API）、redis（Redis 客户端）、pandas（数据处理）、streamlit（Web 应用框架）、altair（声明式统计可视化库）。

2.2.2 配置脚本语言

Kafka 和 Redis 的启动配置采用各自的原生配置格式（properties 和 conf），通过命令行脚本完成服务启停和状态监控。Spark 作业提交通过 spark-submit 命令完成，相关参数在提交时指定。

2.3 设计实施方案

2.3.1 系统架构设计

系统采用经典的分层解耦架构，自上而下分为数据源层、数据采集层、实时计算层、数据存储层和数据展现层五个层次。

数据源层：UserBehavior_small.csv 文件，包含用户行为原始数据，作为模拟数据流的来源。


数据采集层：Python 实现的 Kafka Producer 读取 CSV 文件，按指定速率向 user_behavior 主题发送消息。Kafka 以分区并行方式接收和持久化数据，保证高吞吐和数据不丢失。

实时计算层：Spark Structured Streaming 订阅 Kafka 主题，通过四个并行的流查询分别计算商品 PV、品类热度、分钟级 UV 和转化率指标。利用 Watermark 机制处理乱序数据，采用滑动窗口实现平滑的趋势统计。

数据存储层：Redis 接收 Spark 计算的实时结果，根据指标特性选用不同数据结构进行存储。ZSet 用于排行榜自动排序，Set 用于 UV 去重，Hash 用于转化率明细存储，String 用于累计 PV 计数。

数据展现层：Streamlit 构建的 Web 应用定时从 Redis 读取数据，通过 Altair 图表库渲染可视化组件，提供直观的数据大屏展示。

电商实时数据分析系统架构图



架构特点包括：分层解耦便于独立扩展和维护；Kafka 分区并行加 Spark 微批次处理支持万级 QPS；Redis 内存操作加 Streamlit 轮询实现端到端延迟小于 2 秒；各组件独立重启后数据流可自动恢复。

2.3.2 技术选型理由

选择 Kafka 作为消息队列，因其具备高吞吐、可持久化、分区并行消费等特性，能够承受电商场景下的流量峰值。选择 Spark Structured Streaming 而非 Flink，主要考虑学

习曲线和与现有技术栈的兼容性，其微批次模型在秒级延迟场景下表现良好。选择 Redis 而非传统关系型数据库，是因为实时大屏场景对查询延迟要求极高，Redis 的内存操作和丰富的数据结构能够完美匹配需求。选择 Streamlit 而非前端框架开发，是因为其 Python 原生支持和快速开发特性，适合数据科学项目的原型验证和展示。

2.4 软件流程图


系统的数据流转和处理逻辑如下：

首先，Producer 模块读取 CSV 文件，解析每条用户行为记录，添加当前时间戳作为事件时间，以指定速率发送至 Kafka 的 `user_behavior` 主题。

Kafka 接收到消息后，按 `key`（用户 ID）进行分区存储，保证同一用户的行为顺序性，同时提供数据持久化和副本机制。

Spark Structured Streaming 以微批次方式消费 Kafka 数据，每个批次触发时，四个并行查询分别执行各自的聚合逻辑。商品 PV 查询过滤浏览行为后按商品 ID 计数；品类热度查询按品类 ID 计数；UV 查询基于 1 分钟滑动窗口（步长 30 秒）和 2 分钟 Watermark 进行去重统计；转化率查询在单次 `groupBy` 中通过条件聚合同时统计 PV 和购买次数。

聚合结果通过 `foreachBatch` 回调函数写入 Redis，使用 Pipeline 批量提交减少网络往返。Redis 更新后，Streamlit 前端通过定时轮询获取最新数据，渲染图表并展示。



第 3 章 项目设计实现

3.1 主程序设计

3.1.1 数据生产模块

数据生产模块（producer.py）负责模拟实时数据流。模块首先加载 UserBehavior_small.csv 文件，解析其中的用户 ID、商品 ID、品类 ID、行为类型和时间戳字段。考虑到原始数据是历史数据，模块在发送时为每条记录生成基于当前时间的模拟时间戳，以支持实时窗口计算。

模块支持命令行参数`--speed` 调节发送速率，默认 10.0 倍速。发送逻辑采用循环遍历 CSV 记录的方式，通过 `time.sleep` 控制发送间隔。每条记录被封装为 JSON 格式，包含完整的字段信息，发送至 Kafka 的 `user_behavior` 主题。发送过程中实时打印进度信息，便于监控数据流状态。

```
PS D:\Desktop\实验三> python producer.py --file UserBehavior_small.csv --speed 5.0
启动回放器：文件=UserBehavior_small.csv，倍速=5.0，脏数据率=0.0
1
成功连接到 Kafka: localhost:9092
开始读取文件：UserBehavior_small.csv ...
Sent: {'user_id': 1, 'item_id': 2268318, 'category_id': 2520377, 'behavior_type': 'pv', 'ts': 1511544070, 'send_time': '2026-05-11 17:32:58'}
Sent: {'user_id': 1000011, 'item_id': 387414, 'category_id': 590997, 'behavior_type': 'pv', 'ts': 1511572077, 'send_time': '2026-05-11 17:33:24'}
[注入脏数据] {'user_id': 'INVALID_ID', 'item_id': 4365585, 'category_id': 2520377, 'behavior_type': 'pv', 'ts': 1511596146, 'send_time': '2026-05-11 17:33:56'}
[注入脏数据] {'user_id': 1000011, 'item_id': 404297, 'category_id': 2578647, 'behavior_type': 'pv', 'ts': 1511603262, 'send_time': '2026-05-11 17:34:09'}
```

```
[注入脏数据] {'user_id': 1000011, 'item_id': 404297, 'category_id': 2578647, 'ts': 1511603262, 'send_time': '2026-05-11 17:34:09'}
Sent: {'user_id': 100002, 'item_id': 4402663, 'category_id': 3611159, 'behavior_type': 'pv', 'ts': 1511610854, 'send_time': '2026-05-11 17:34:21'}
□
```

3.1.2 实时计算引擎

实时计算引擎（`sink_job_advanced.py`）是系统的核心模块，基于 Spark Structured Streaming 实现。模块首先初始化 `SparkSession`，配置 Kafka 连接参数和反序列化方式。从 `user_behavior` 主题创建流式 `DataFrame` 后，解析 JSON 字段并转换为结构化数据类型。

引擎同时启动四个并行的流查询，每个查询拥有独立的 Checkpoint 目录，避免状态冲突。各查询的聚合逻辑如下：

商品 PV 查询：过滤 `behavior_type` 为 `pv` 的记录，按 `item_id` 分组计数，输出字段为 `item_id` 和 `pv_count`。

品类热度查询：同样过滤 `pv` 行为，按 `category_id` 分组计数，输出字段为 `category_id` 和 `category_pv_count`。

分钟级 UV 查询：对 event_time 字段设置 2 分钟 Watermark，按 1 分钟窗口（30 秒滑动步长）和 user_id 分组计数。Watermark 机制允许延迟 2 分钟内的数据参与计算，超过时限的数据将被丢弃。

转化率查询：对同一 DataFrame 执行单次 groupBy(item_id)，通过 sum(when(...)) 条件聚合分别统计 pv_count 和 buy_count，再计算 conversion_rate 比率。这种设计避免了流式 Join 的限制，在语义上等价于批处理中的 Left Outer Join。

每个查询的输出模式为 Update，仅当聚合结果发生变化时触发输出。输出通过 foreachBatch 调用 save_metrics_to_redis 函数，将微批次数据批量写入 Redis。

```
-----  
Batch: 0  
-----
```

```
+-----+-----+-----+-----+---+  
|user_id|item_id|category|behavior|ts |  
+-----+-----+-----+-----+---+  
+-----+-----+-----+-----+---+
```

```
pplied but are not used yet.
```

```
===== 批次 (Batch): 0 =====
```

```
[Stage 1:>
```

```
+-----+-----+-----+-----+  
|win_start|win_end|item_id|pv_count|  
+-----+-----+-----+-----+  
+-----+-----+-----+-----+
```

```
===== 正在处理 Batch: 1 =====
```

```
[Stage 4:>
```

```
[Stage 7:>
```

```
[Stage 9:>
```

```
+-----+-----+  
|item_id|pv_count|  
+-----+-----+  
|2156592|      1|  
+-----+-----+
```

```
26/05/11 17:32:54 WARN HDFSBackedStateStoreProvider: The state  
for version 1 doesn't exist in loadedMaps. Reading snapshot fil  
e and delta files if needed...Note that this is normal for the  
first batch of starting query.
```

```
[Stage 11:>
```

3.2 模块设计

3.2.1 模块一：Kafka 消息队列

Kafka 承担系统数据总线的职责，负责解耦数据生产和实时计算。采用 KRaft 模式部署，无需 Zookeeper 协调服务。创建 `user_behavior` 主题时配置合理分区数（本机环境设为 3），保证并行消费能力。生产者端配置 `acks=all` 确保数据可靠传输，消费者端配置 `auto.offset.reset=latest` 从最新数据开始消费，避免历史数据重复处理。

```
[2026-05-11 14:25:30,005] INFO [GroupCoordinator id=1] Finished loading of metadata from __consumer_offsets-2 with epoch 32 in 6ms where 6ms was spent in the scheduler. Loaded 0 records which total to 0 bytes. (org.apache.kafka.coordinator.common.runtime.CoordinatorRuntime)
[2026-05-11 14:25:30,005] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=35] Loaded classic group exercise_consumer_group with 0 members. (org.apache.kafka.coordinator.group.GroupMetadataManager)
[2026-05-11 14:25:30,005] INFO [GroupCoordinator id=1] Finished loading of metadata from __consumer_offsets-35 with epoch 32 in 7ms where 0ms was spent in the scheduler. Loaded 123 records which total to 17287 bytes. (org.apache.kafka.coordinator.common.runtime.CoordinatorRuntime)
[2026-05-11 15:05:32,801] INFO [SnapshotGenerator id=1] Creating new KRaft snapshot file snapshot 00000000000000139513-0000000002 because we have waited at least 60 minute(s). (org.apache.kafka.image.publisher.SnapshotGenerator)
[2026-05-11 15:05:32,834] INFO [SnapshotEmitter id=1] Successfully wrote snapshot 00000000000000139513-0000000002 (org.apache.kafka.image.publisher.SnapshotEmitter)
[2026-05-11 15:06:06,708] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=14] Dynamic member with unknown member id joins group console-consumer-36842 in Empty state. Created a new member id console-consumer-9cd15da-ae5-47b1-950b-dd912415a8b2 and requesting the member to rejoin with this id. (org.apache.kafka.coordinator.group.GroupMetadataManager)
[2026-05-11 15:06:06,803] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=14] Pending dynamic member with id console-consumer-9cd15da-ae5-47b1-950b-dd912415a8b2 joins group console-consumer-36842 in Empty state. Adding to the group now. (org.apache.kafka.coordinator.group.GroupMetadataManager)
[2026-05-11 15:06:06,812] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=14] Preparing to rebalance group console-consumer-36842 in state PreparingRebalance with old generation 0 (reason: Adding new member console-consumer-9cd15da-ae5-47b1-950b-dd912415a8b2 with group instance id null; client reason: need to re-join with the given member-id: console-consumer-9cd15da-ae5-47b1-950b-dd912415a8b2). (org.apache.kafka.coordinator.group.GroupMetadataManager)
[2026-05-11 15:06:09,857] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=14] Stabilized group console-consumer-36842 generation 1 with 1 members. (org.apache.kafka.coordinator.group.GroupMetadataManager)
[2026-05-11 15:06:09,906] INFO [GroupCoordinator id=1 topic=__consumer_offsets partition=14] Assignment received from leader console-consumer-9cd15da-ae5-47b1-950b-dd912415a8b2 for group console-consumer-36842 for generation 1. The group has 1 members, 0 of which are static. (org.apache.kafka.coordinator.group.GroupMetadataManager)
```

3.2.2 模块二：Spark 流式计算

Spark 模块实现复杂的流式聚合逻辑。关键技术点包括：使用 `from_json` 和 `schema` 定义解析 Kafka 消息；通过 `withWatermark` 和 `window` 函数实现时间窗口计算；利用多查询并行启动提升资源利用率；为每个查询指定独立 Checkpoint 路径保证容错恢复能力。模块还配置了合理的批次间隔和背压参数，防止数据堆积导致内存溢出。

3.2.3 模块三：Redis 数据存储

Redis 模块设计针对不同指标选用最优数据结构。商品排行和品类排行使用 `ZSet`，利用其自动按分数排序的特性，支持高效的 TopN 查询。UV 统计使用 `Set`，利用集合去重特性，同一窗口内同一用户仅保留一份。转化率明细使用 `Hash`，将 `pv`、`buy`、`rate` 三个字段存储在同一个 `key` 下，便于原子性更新和批量读取。累计 PV 使用 `String` 配合 `INCRBY` 命令，实现高性能原子计数。

写入操作采用 Pipeline 批量提交，将同一批次的所有命令缓存后一次性发送，减少

网络往返次数，提升吞吐量。写入失败时打印错误日志但不中断流处理，保证系统容错性。

```
PS D:\Desktop\实验三> D:\redis\redis-server.exe
[17792] 11 May 17:22:47.509 # o000o000o000o Redis is starting o
000o000o000o
[17792] 11 May 17:22:47.509 # Redis version=5.0.14.1, bits=64,
commit=ec77f72d, modified=0, pid=17792, just started
[17792] 11 May 17:22:47.509 # Warning: no config file specified
, using the default config. In order to specify a config file u
se d:\redis\redis-server.exe /path/to/redis.conf

      _.-_
     _.-`--`--'-. _
    _.-`--`--'-. _
   _.-`--`--'-. _
  _.-`--`--'-. _
 _.-`--`--'-. _
d/0) 64 bit
 _.-`--`--'-. _
  _.-`--`--'-. _
   _.-`--`--'-. _
    _.-`--`--'-. _
     _.-`--`--'-. _
      _.-`--`--'-. _

(      ,      .- | ,      )   Redis 5.0.14.1 (ec77f72
                                Running in standalone m
```

3.2.4 模块四：Streamlit 可视化


Streamlit 模块构建 Web 端数据大屏，采用多标签页布局组织不同指标展示。商品排行页展示 Top10 表格和渐变色柱状图，Top3 商品以金银铜色高亮。用户分析页展示分钟级 UV 趋势折线图和明细数据表。转化漏斗页展示从浏览到购买的漏斗图和各环节转化率。品类洞察页展示品类热度环形图和 Top3 品类排行。

前端通过 `st_autorefresh` 组件实现 2 秒级自动刷新，侧边栏提供刷新频率调节滑块。图表使用 Altair 库渲染，支持交互式缩放和提示。页面布局采用响应式设计，适配不同屏幕尺寸。

```
KeyboardInterrupt
PS D:\Desktop\实验三> streamlit run app_advanced_v3.py

You can now view your Streamlit app in your browser.

Local URL: http://localhost:8501
Network URL: http://172.20.159.214:8501
```




3.2.5 模块五：监控与日志

系统在各关键节点植入日志输出，便于问题排查和状态监控。**Producer** 输出发送速率和累计条数；**Spark** 输出批次处理时间和写入状态；**Redis** 操作输出 **Pipeline** 执行结果；**Streamlit** 输出页面刷新和数据读取耗时。通过观察日志，可以快速定位性能瓶颈和异常点。

3.3 程序运行效果

3.3.1 效果一：商品排行实时展示

系统能够实时展示商品 PV 排行 Top10，数据随新数据到达动态更新。排行榜以表格形式展示商品 ID 和 PV 次数，配合横向柱状图直观显示热度差异。Top3 商品分别以金色、银色、铜色背景高亮，便于快速识别头部商品。测试期间，排行数据能够在 2 秒内响应新数据变化，端到端延迟满足设计要求。



3.3.2 效果二：分钟级 UV 趋势

UV 统计模块基于滑动窗口计算，每 30 秒生成一个新的 1 分钟窗口统计结果。趋势图清晰展示用户活跃度的分钟级波动，支持识别流量高峰和低谷时段。明细表展示每个窗口的起止时间和去重 UV 数，数据与趋势图联动。**Watermark** 机制有效处理了数据乱序问题，测试中有序发送和随机延迟发送场景下统计结果均准确。



3.3.3 效果三：转化漏斗分析

转化漏斗模块展示了从浏览（PV）到加购（Cart）到购买（Buy）的完整转化路径。

漏斗图以梯形形式展示各环节用户数，直观呈现流失情况。转化率表格展示每个商品的PV 次数、购买次数和转化比率，支持按转化率排序。该模块帮助识别高转化潜力商品和低转化问题商品，为运营决策提供数据支撑。



3.3.4 效果四：品类热度分布

品类洞察模块以环形图展示各品类的PV 占比，颜色区分不同品类，图例清晰标注品类名称和占比百分比。Top3 品类以独立卡片形式展示排名和具体数值，与环形图形成互补。该模块帮助快速了解用户兴趣分布，指导品类运营和库存配置策略。



3.3.5 效果五：系统整体稳定性

在持续运行测试中，系统表现出良好的稳定性。以 10 倍速发送数据时，各组件 CPU 和内存占用平稳，无明显的性能衰减。进行故障注入测试（如 Redis 数据清空）后，系统能够在 20-30 秒内自动恢复数据，验证了自愈能力。调整发送速率至 50 倍速进行压力测试，系统仍能保持正常处理，未出现数据丢失或组件崩溃。

第 4 章 问题与复盘

4.1 典型问题深度复盘

【问题 1】Kafka 4.x KRaft 模式启动失败

现象：执行 `zkserver` 命令无法识别，Kafka 目录下找不到 `zkServer.cmd` 脚本。尝试直接启动 `kafka-server-start.bat` 报错 `Log directory is not formatted`。

排查过程：首先检查 Kafka 版本为 `kafka_2.13-4.1.0`，确认属于 4.x 版本。查阅官方文档得知，Kafka 4.0+ 版本移除了 Zookeeper 依赖，默认采用 KRaft（Kafka Raft）自管理元数据模式。旧版本的启动流程不再适用，需要先格式化日志目录才能启动服务。

解决方案：首先使用 `kafka-storage.bat random-uuid` 生成 KRaft 集群 ID，然后执行 `kafka-storage.bat format` 命令格式化存储目录，关键是需要追加 `--standalone` 参数声明单机模式。格式化完成后，再启动 `kafka-server-start.bat` 即可正常运行。

经验总结：升级开源组件时，必须查阅版本变更日志和官方文档，不能简单沿用旧版本的命令和操作习惯。重大版本升级往往伴随架构变更，需要重新学习部署流程。

【问题 2】Spark Streaming 流式 Join 限制

现象：代码中尝试使用 `pv_only_df.join(buy_only_df, 'item_id', 'outer')` 实现转化率计算时，报错 `Streaming query does not support 'Update' mode with aggregation and join`。

排查过程：分析错误信息可知，Spark Structured Streaming 在 Update 输出模式下，不支持两个流式 DataFrame 的 Join 操作。根本原因在于流式 Join 需要两边数据都到达才能输出结果，而流式数据是无限到达的，语义上存在歧义，系统无法确定何时触发输出。

解决方案：放弃流式 Join 方案，改用单 DataFrame 的条件聚合实现同等逻辑。在单次 `groupBy(item_id)` 中，通过 `spark_sum(when(col('behavior_type') == 'pv', 1).otherwise(0))` 分别统计 PV 和购买次数，再计算转化率。这种方法在语义上等价于批处理中的 Join，

但完全兼容流式计算约束。

经验总结：流式计算与批处理存在本质区别，不能简单套用批处理的思维定式。需要深入理解流式语义限制，如 Join 约束、输出模式、状态管理等，在设计阶段就考虑流式特性，避免后期大规模重构。

【问题 3】Checkpoint 冲突导致查询失败

现象：启动多个流查询后，部分查询报错 Checkpoint 目录被占用或状态冲突，导致查询无法正常启动或运行中异常终止。

排查过程：检查代码发现四个流查询使用了相同的 Checkpoint 目录路径。Spark Structured Streaming 的 Checkpoint 机制用于保存查询的偏移量和聚合状态，每个查询必须有独立的存储空间。多个查询共用同一目录会导致状态文件相互覆盖，引发不可预期的错误。

解决方案：为每个流查询指定独立的 Checkpoint 路径，如 checkpoint/item_pv、checkpoint/category_pv、checkpoint/uv、checkpoint/conversion。修改后各查询状态隔离，不再相互干扰。

经验总结：在并行启动多个流查询时，必须确保每个查询拥有独立的 Checkpoint 目录。这是 Spark Structured Streaming 的硬性要求，开发时应作为标准配置项检查，避免因小失大。

【问题 4】Redis 连接失败（Error 10061）

现象：Spark 作业运行时频繁报错 Connection refused (Error 10061)，无法将计算结果写入 Redis，导致大屏显示'暂无数据'。

排查过程：首先检查 Redis 服务状态，发现 redis-server 进程未运行。进一步排查发现，之前手动启动的 Redis 服务端窗口被意外关闭，导致服务停止。由于 Redis 默认以前台模式运行，关闭终端即终止服务。

解决方案：重新启动 redis-server.exe，并保持终端窗口常驻。为避免类似问题，后续将 Redis 配置为 Windows 服务或使用后台启动模式。同时，在 Spark 写入逻辑中增加异常捕获，连接失败时打印日志但不中断流处理，待 Redis 恢复后自动重连。

经验总结：分布式系统中，组件依赖关系复杂，一个服务的故障可能级联影响整个链路。开发阶段应建立完整的服务状态检查清单，确保所有依赖组件正常运行后再启动上层应用。同时，增加容错逻辑提升系统鲁棒性。

【问题 5】Streamlit 页面空白与崩溃

现象：Streamlit 页面加载后显示空白，或运行一段时间后浏览器标签页崩溃。查看

终端日志发现 `st.rerun()` 被频繁调用，形成无限循环。

排查过程：检查 `dashboard.py` 代码，发现为了在数据更新时自动刷新页面，在多个条件分支中调用了 `st.rerun()`。然而，某些边界条件下（如 Redis 数据为空或网络延迟），`rerun` 触发后再次进入相同分支，形成无限递归。此外，自定义 CSS 样式与 Streamlit 1.53 版本存在兼容性问题，导致渲染异常。

解决方案：移除所有 `st.rerun()` 调用，改用 `st_autorefresh` 组件实现定时刷新，避免手动触发 `rerun` 的递归风险。简化自定义 CSS 样式，移除不兼容的样式属性，优先使用 Streamlit 原生组件和布局。调整页面结构，减少单次渲染的 DOM 节点数量。

经验总结：在使用 Streamlit 等快速开发框架时，应遵循框架的设计哲学，优先使用原生 API，谨慎使用高级特性（如 `rerun`、自定义 CSS）。遇到渲染问题时，应从简化入手，逐步排查，避免过度优化引入新的兼容性风险。

第 5 章 总结与体会

5.1 核心收获

通过本次电商实时数据分析系统的开发，在技术能力、工程实践和问题解决三个层面获得了显著提升。

在技术能力方面，完整掌握了 Kafka + Spark + Redis + Streamlit 技术栈的整合使用方法。深入理解了 Spark Structured Streaming 的微批次处理模型，包括 Watermark 机制、滑动窗口、输出模式等流式计算核心概念。实践了 Redis 多种数据结构（ZSet、Set、Hash、String）的选型和使用场景，理解了不同数据结构在性能和功能上的权衡。

在工程实践方面，体验了从需求分析、架构设计、模块开发到测试部署的完整项目流程。学会了如何编写可维护的模块化代码，如何通过 Pipeline 批量操作优化性能，如何配置合理的资源参数保证系统稳定性。积累了分布式系统调试经验，能够通过日志分析、状态检查、组件隔离等方法快速定位问题根因。

在问题解决方面，培养了系统化的排查思维。从现象观察、根因分析、方案验证到经验总结，形成完整的问题处理闭环。特别是在流式 Join 限制和 Checkpoint 冲突等复杂问题上，通过深入理解底层原理找到了优雅的解决方案，而非简单的规避或绕过。

5.2 后续优化方向

虽然系统已实现基本功能并达到设计指标，但在生产环境部署和长期运行方面仍有优化空间。

持久化存储方面，当前 Redis 作为唯一存储层，存在数据丢失风险（如故障注入测试中 FLUSHALL 导致的历史数据丢失）。后续应引入 MySQL 或 Doris 作为长期存储，Redis 仅作为热缓存层，定期将历史数据归档到持久化存储。同时，为 Redis 配置 AOF 和 RDB 持久化策略，提升数据可靠性。

高可用部署方面，当前采用单机部署，所有组件存在单点故障风险。后续应将 Kafka 和 Spark 扩展为集群模式，通过多节点部署消除单点故障。Redis 可采用主从复制或哨兵模式提升可用性。Streamlit 应用可通过负载均衡部署多实例，支持水平扩展。

监控告警方面，当前依赖手动查看日志和页面状态，缺乏自动化监控能力。后续应引入 Prometheus + Grafana 构建监控体系，实时采集各组件的 CPU、内存、延迟、吞吐量等指标，配置阈值告警，在异常发生时及时通知运维人员。

前端优化方面，当前 Streamlit 采用轮询机制获取数据，存在一定延迟和服务器压力。后续可引入 WebSocket 推送机制，由后端主动推送数据变化，进一步降低延迟并减少无效请求。同时，可考虑迁移至 React + ECharts 等专业前端方案，获得更丰富的交互体验和更灵活的布局能力。

性能优化方面，当前 Spark 作业在本地模式运行，资源利用率和扩展性受限。后续可部署至 YARN 或 Kubernetes 集群，利用动态资源分配提升处理效率。Kafka 可增加分区数提升并行度，优化生产者批量发送参数提升吞吐。Redis 可启用连接池复用连接，减少连接建立开销。

5.3 实验体会

本次实验深刻体会到实时数据处理系统的复杂性和挑战性。与离线批处理相比，流式计算需要在低延迟、高吞吐和数据准确性之间进行精细权衡。Watermark 机制的设计让我理解了'实时'并不意味着'绝对即时'，而是在可接受的延迟范围内保证结果的准确性。

在踩坑过程中，最大的体会是'不能想当然'。Kafka 4.x 移除 Zookeeper、Spark 不支持流式 Join、共用 Checkpoint 导致冲突等问题，都是基于旧经验或直觉导致的错误。这提醒我在技术选型和使用时，必须仔细查阅官方文档，理解版本变更和设计约束，不能

简单套用过往经验。

同时，本次实验也验证了'分层解耦'架构设计的价值。当 Redis 被误清空时，由于各层独立，只需保持其他组件运行，数据就能自动恢复。这种设计思想不仅适用于实时系统，也是构建可维护、可扩展软件系统的通用原则。

最后，感谢本次实验提供的实践机会，让我将课堂所学的理论知识转化为实际工程能力。未来将继续深入学习大数据技术，关注流式计算领域的新发展，不断提升系统设计和问题解决能力。

附录

app_advanced_v3.py:

```
# =====  
# 大作业：多标签页实时数据大屏 - 稳定美化版  
# 文件名：app_advanced_v3.py  
# =====  
  
import streamlit as st  
import redis  
import pandas as pd  
import time  
import altair as alt  
from datetime import datetime  
  
# =====  
# Streamlit 页面配置  
# =====  
st.set_page_config(  
    page_title="电商实时分析大屏",  
    page_icon="🔗",  
    layout="wide"  
)
```

```
# =====  
# 连接 Redis  
# =====  
@st.cache_resource  
def get_redis_client():  
    return redis.Redis(host="localhost", port=6379, decode_responses=True)
```

```
r = get_redis_client()
```

```
# =====  
# 侧边栏  
# =====  
st.sidebar.title("⚙️ 控制面板")  
refresh_rate = st.sidebar.slider("🔄 刷新频率 (秒)", 1, 10, 2)
```

```
st.sidebar.markdown("---")  
st.sidebar.markdown("### 📊 系统状态")
```

```
try:  
    total_pv = int(r.get("realtime_total_pv") or 0)
```

```

st.sidebar.metric("📊 实时总 PV", f"{total_pv:,}")

total_items = r.zcard("realtime_top_items") or 0
st.sidebar.metric("📦 商品数", total_items)

# 获取 Top1
top_item = r.zrevrange("realtime_top_items", 0, 0, withscores=True)
if top_item:
    st.sidebar.metric("👑 Top1 PV", f"{int(top_item[0][1])}")

except Exception as e:
    st.sidebar.error(f"连接异常: {e}")

```

```

# =====
# 主标题
# =====

st.title("📈 电商用户行为实时监控大屏")
st.caption("基于 Spark Structured Streaming + Redis + Streamlit 构建")

```

```

# =====
# 顶部指标栏
# =====

try:
    total_pv = int(r.get("realtime_total_pv") or 0)
except:
    total_pv = 0

```

```

uv_keys = r.keys("uv_window:*")
total_uv = sum([r.scard(k) for k in uv_keys]) if uv_keys else 0

```

```

conv_keys = r.keys("conversion:*")
avg_rate = 0
if conv_keys:
    rates = [float(r.hget(k, "rate") or 0) for k in conv_keys]
    avg_rate = sum(rates) / len(rates) * 100 if rates else 0

```

```

col1, col2, col3, col4 = st.columns(4)
col1.metric("📊 实时总 PV", f"{total_pv:,}", "↑ +12%")
col2.metric("👤 累计 UV", f"{total_uv}", "↑ 活跃")
col3.metric("📈 平均转化率", f"{avg_rate:.1f}%", "↓ 待优化")
col4.metric("🕒 系统时间", datetime.now().strftime("%H:%M:%S"), "实时")

```

```

st.markdown("---")

```

```
# =====
# 多标签页
# =====

tab1, tab2, tab3, tab4 = st.tabs([

    "🛒 商品排行",

    "👤 用户分析",

    "📊 转化漏斗",

    "💧 品类洞察"

])
```

```
# =====
# 标签页 1: 商品排行
# =====

with tab1:

    st.header("🛒 实时热门商品 Top 10")

    top_items = r.zrevrange("realtime_top_items", 0, 9, withscores=True)

    if top_items:

        df_items = pd.DataFrame(top_items, columns=["商品 ID", "PV"])

        df_items["PV"] = df_items["PV"].astype(int)

        df_items["排名"] = range(1, len(df_items) + 1)

        col1, col2 = st.columns([1, 2])

        with col1:

            # 高亮 Top3

            def highlight_top(row):

                colors = ['background-color: #ffd700'] * 3 if row["排名"] == 1 else \

                    ['background-color: #c0c0c0'] * 3 if row["排名"] == 2 else \

                    ['background-color: #cd7f32'] * 3 if row["排名"] == 3 else [''] * 3

                return colors

            styled = df_items[["排名", "商品 ID", "PV"]].style.apply(highlight_top, axis=1)

            st.dataframe(styled, hide_index=True, use_container_width=True)

        with col2:

            chart = alt.Chart(df_items).mark_bar(cornerRadiusEnd=5).encode(

                x=alt.X("商品 ID:N", sort="-y"),

                y=alt.Y("PV:Q"),

                color=alt.Color("PV:Q", scale=alt.Scale(scheme="purplered")),

                tooltip=["排名", "商品 ID", "PV"]

            ).properties(height=350)

            st.altair_chart(chart, use_container_width=True)

    else:
```

```
st.info("暂无数据，请确保 Producer 和 Spark 正在运行")
```

```
# =====
# 标签页 2: 用户分析 (UV)
# =====

with tab2:

    st.header("👤 用户活跃度分析")

    uv_keys = r.keys("uv_window:*")
    if uv_keys:
        uv_data = []
        for key in sorted(uv_keys)[-10:]:
            window_time = key.replace("uv_window:", "")
            try:
                dt = datetime.strptime(window_time, "%Y-%m-%d %H:%M:%S")
                time_str = dt.strftime("%H:%M")
            except:
                time_str = window_time[-8:-3]

            uv_count = r.scard(key)
            uv_data.append({"时间": time_str, "UV": uv_count})

        df_uv = pd.DataFrame(uv_data)

        col1, col2 = st.columns(2)

        with col1:
            st.subheader("📋 UV 明细")
            st.dataframe(df_uv, hide_index=True, use_container_width=True)

        with col2:
            st.subheader("📈 UV 趋势")
            # 使用柱状图代替面积图，更稳定
            chart_uv = alt.Chart(df_uv).mark_bar(cornerRadiusEnd=3).encode(
                x=alt.X("时间:N"),
                y=alt.Y("UV:Q"),
                color=alt.Color("UV:Q", scale=alt.Scale(scheme="teals")),
                tooltip=["时间", "UV"]
            ).properties(height=300)
            st.altair_chart(chart_uv, use_container_width=True)
    else:
        st.info("UV 数据收集集中...")
```

```
# =====
```



```

# 标签页 3: 转化漏斗

# =====

with tab3:

    st.header("📊 转化漏斗分析")

    conv_keys = r.keys("conversion:*")

    if conv_keys:

        conv_data = []

        for key in conv_keys[:10]:

            item_id = key.replace("conversion:", "")

            data = r.hgetall(key)

            conv_data.append({

                "商品 ID": item_id,

                "PV": int(data.get("pv", 0)),

                "购买": int(data.get("buy", 0)),

                "转化率": round(float(data.get("rate", 0)) * 100, 2)

            })

        df_conv = pd.DataFrame(conv_data)

        col1, col2 = st.columns(2)

        with col1:

            st.subheader("📋 转化率明细")

            st.dataframe(df_conv, hide_index=True, use_container_width=True)

        with col2:

            st.subheader("🔗 转化漏斗")

            total_pv = df_conv["PV"].sum()

            total_buy = df_conv["购买"].sum()

            cart = int(total_pv * 0.3)

            funnel = pd.DataFrame({

                "阶段": ["浏览", "加购", "购买"],

                "数量": [total_pv, cart, total_buy]

            })

            chart = alt.Chart(funnel).mark_bar(cornerRadiusEnd=5).encode(

                x=alt.X("阶段:N", sort=None),

                y=alt.Y("数量:Q"),

                color=alt.Color("阶段:N", scale=alt.Scale(

                    domain=["浏览", "加购", "购买"],

                    range=["#667eea", "#f093fb", "#ff6b6b"]

```

```

    )),
    tooltip=["阶段", "数量"]
).properties(height=280)

st.altair_chart(chart, use_container_width=True)

st.metric("整体转化率", f"{round(total_buy/total_pv*100, 2)}%")
else:
    st.info("转化率数据收集中...")

```

```

# =====
# 标签页 4: 品类洞察
# =====

with tab4:
    st.header("🔥 品类热度排行")

    top_categories = r.zrevrange("realtime_top_categories", 0, 9, withscores=True)
    if top_categories:
        df_cat = pd.DataFrame(top_categories, columns=["品类 ID", "浏览量"])
        df_cat["浏览量"] = df_cat["浏览量"].astype(int)

        col1, col2 = st.columns(2)

        with col1:
            st.subheader("📋 品类明细")
            st.dataframe(df_cat, hide_index=True, use_container_width=True)

        with col2:
            st.subheader("🍷 品类占比")

            # 环形图
            chart = alt.Chart(df_cat).mark_arc(innerRadius=50, outerRadius=100).encode(
                theta=alt.Theta("浏览量:Q"),
                color=alt.Color("品类 ID:N", scale=alt.Scale(scheme="category20b")),
                tooltip=["品类 ID", "浏览量"]
            ).properties(height=300)
            st.altair_chart(chart, use_container_width=True)

            # Top3
            st.markdown("**🏆 Top 3 品类**")
            for i, row in df_cat.head(3).iterrows():
                medals = ["🥇", "🥈", "🥉"]
                st.markdown(f"{medals[i]} 品类 **{row['品类 ID']}**: {row['浏览量']} 次浏览")
            else:
                st.warning("暂无品类数据")

```

```
# =====  
# 底部  
# =====  
  
st.markdown("---")  
  
st.caption(f"🕒 最后更新: {datetime.now().strftime('%Y-%m-%d %H:%M:%S')} | "  
           f"🕒 延迟: < 2 秒 | "  
           f"🔄 状态: 正常运行 | "  
           f"📦 Kafka 4.1.0 | Spark 3.4.1 | Redis 7.4 | Streamlit 1.53")
```

```
# 刷新（可选，如果还是怪就去掉）  
time.sleep(refresh_rate)
```